

SAE 401

Prédiction du Prix Médian des Logements à Boston

Expliquer / Prédire une variable quantitative

COURSON Quentin
LESBASTARD Cléo
POIRIER Lucas
UGUEN Paul

2025 — 2026

SOMMAIRE

I. Introduction

1.1 Contexte

1.2 Variables

II. Analyses

2.1 Analyse univariée

2.1.1 Variable cible : medv

2.1.2 Variables explicatives

2.1.3 Variable qualitative : Bordure rivière Charles

2.2 Analyse Bivariée

2.2.1 Relation avec la variable cible (medv)

III. Modélisation de découverte

3.1 Premier modèle — $\text{medv} \sim \text{rm}$

3.1.1 Diagnostics des résidus

3.2 Deuxième modèle — $\text{medv} \sim \text{lstat} + \text{lstat}^2$

3.3 Troisième modèle — modèle complet

3.3.1 Construction du modèle

3.3.2 Vérification des hypothèses

IV. Sélection du Meilleur Modèle

4.1 Méthode Forward (sélection progressive)

4.2 Méthode Backward (élimination progressive)

4.3 Méthode Stepwise

4.4 Méthode Exhaustive

4.5 Comparaison finale

V. Modèle Final

5.1 Présentation du modèle retenu

5.2 Interprétation des coefficients

- Variables à impact positif sur les prix
- Variables non significatives

5.3 Diagnostics du modèle final

VI. Prédictions Concrètes à Boston

6.1 Application du modèle

VII. Conclusion

7.1 Modèle final

7.2 Interprétation des résultats

7.3 Limites et perspectives

I. Introduction

1.1 Contexte

La mission qui nous a été confiée est d'étudier le prix des logements à Boston. Le jeu de données fourni contient 506 observations qui correspondent à des zones urbaines distinctes de la ville. Chaque observation décrit un ensemble de caractéristiques socio-économiques, environnementales et structurelles des logements, telles que le taux de criminalité, la proportion de terrains résidentiels, l'accessibilité aux axes routiers ou encore la qualité de l'air.

À partir de ces données, nous chercherons d'une part à identifier et analyser les différents facteurs qui influencent la variable que l'on souhaite expliquer, c'est-à-dire le prix médian des logements (medv). D'autre part, nous allons mettre en œuvre différents modèles prédictifs, afin d'estimer cette variable dans le but de sélectionner le plus performant suivant différents critères d'évaluation.

L'objectif est de prédire le prix médian des logements (medv). Dans une optique prédictive, le critère retenu est uniquement le RMSE (Root Mean Square Error) — l'erreur moyenne de prédiction en k\$. Minimiser le RMSE = maximiser la précision prédictive.

1.2 Variables


On rappelle que les variables du jeu de données sont les suivantes :

Variable	Nature	Description
crim	Quant. continue	Taux de criminalité per capita
zn	Quant. continue	% terrains résidentiels zonés > 25 000 pi ²
indus	Quant. continue	% acres commerce non résidentiel
chas	Qualitative binaire	Bordure rivière Charles (1 = oui)
nox	Quant. continue	Concentration oxydes nitriques ($\times 10^{-7}$)
rm	Quant. continue	Nombre moyen de pièces par logement
age	Quant. continue	% logements construits avant 1940
dis	Quant. continue	Distance pondérée aux centres d'emploi
rad	Quant. discrète	Indice accessibilité autoroutes
tax	Quant. continue	Taux d'imposition (pour 10 000 \$)
ptratio	Quant. continue	Ratio élèves / enseignant
lstat	Quant. continue	% population à faible statut socio-éco.
medv	Quant. continue — CIBLE	Prix médian des logements (k\$)


II. Analyses

2.1 Analyse univariée

2.1.1 Variable cible : Prix médian des maisons



Selon le test de Shapiro-Wilk, le prix médian des maisons à Boston ne suit pas une loi normale. Les graphiques permettent d'identifier un seuil établi du prix médian des maisons à 50 000 \$. On peut supposer que les prix réels sont plus élevés en réalité, ce qui va fausser notre modèle si nous laissons ces valeurs. Nous allons donc utiliser cette variable recodée pour l'ensemble de nos prédictions.




2.1.2 Variable qualitative : Bordure rivière Charles (Bordure de la rivière charles)

La variable Bordure rivière Charles est une variable binaire indiquant si le secteur borde la rivière Charles (1 = oui, 0 = non). Une grande partie des habitations (93,1%) ne sont pas à côté de la rivière Charles.

2.2 Analyse Bivariée

2.2.1 Relation avec la variable cible (medv)

Figure 2 — Matrice de dispersion : medv et principaux prédicteurs



L'utilisation de `ggpairs()` permet d'identifier les corrélations entre toutes les variables et de justifier les choix de modélisation. La présence du terme $lstat^2$ (population défavorisée en % au carré) est confirmée par la non-linéarité observée sur la matrice de corrélation. La corrélation de Pearson entre le taux d'imposition et l'indice d'accessibilité aux autoroutes est supérieure à 0,90, ce qui constitue un signal fort de multi colinéarité entre ces 2 variables, ce qui pourrait invalider les hypothèses du modèle. Ces deux variables mesurent des dimensions proches de l'accessibilité et de la fiscalité locale et ont tendance à évoluer ensemble. Cela signifie que les coefficients associés à ces variables dans un modèle commun seront difficiles à interpréter séparément.

On remarque aussi des corrélations supérieures à 0.7 entre d'autre variables explicatives comme :

- L'indice d'accessibilité aux autoroutes et le taux d'imposition (0,91)
- La distance aux centres d'emplois et le % acres commercial non résidentiel (-0,71)
- Le Taux d'imposition et le % acres commercial non résidentiel (0,72)
- La concentration oxydes nitriques et le % acres commercial non résidentiel (0,77)

De plus la matrice ggpairs confirme la non-linéarité de la relation entre le % de population défavorisées et le prix médian des maisons (courbure visible dans le nuage de points), et révèle des corrélations fortes entre prédicteurs : La concentration en oxydes nitriques et l'âge de la maison, le % de population défavorisée et l'âge de la maison. Notamment entre le taux d'imposition et l'indice d'accessibilité aux autoroutes. Ces colinéarités entre prédicteurs seront diagnostiquées formellement par le VIF.

III. Modélisation de découverte

Pour cette partie nous rappelons les hypothèses du modèle

- Les erreurs sont centrées autour de 0 (Espérance = 0)
- Les erreurs sont de même variance (homoscédasticité, variance des erreurs égales)

- Les erreurs sont non corrélés entre elles
- Les erreurs suivent une loi Gaussienne $\sim N(0, \sigma^2)$
- Pas de corrélation linéaire entre les variables explicatives

Ce sont les hypothèses que nous devons vérifier pour les différents modèles.

3.1 Premier modèle — prix médian des logements ~ nombre de pièces

Pour ce premier modèle, nous avons décidé d'expliquer le prix médian des logements avec le nombre de pièces : c'est donc un modèle linéaire simple.

$$\text{Prix médian logements} = \beta_0 + \beta_1 \times \text{nombre de pièces logements} + \varepsilon$$

Après l'estimation des paramètres, on trouve que pour chaque pièce supplémentaire dans le logement, le prix médian augmente de 8 270 \$ toutes choses égales par ailleurs. Ce modèle explique environ 47 % de la variance du prix médian des maisons.

3.1.1 Diagnostics des résidus

La visualisation des résidus studentisés (seuil à 2) met en évidence environ une vingtaine d'observations au-delà des seuils fixés, ce qui indique des valeurs atypiques par rapport à la prédiction réalisée.

Le Q-Q plot présente une déviation de la normalité des résidus aux extrémités confirmée par le test de shapiro-wilk (H_0 rejetée à $\alpha = 5\%$), ce qui constitue une limite importante de ce modèle simple.

3.2 Deuxième modèle — Prix médian des maisons = % de la population défavorisée + (% de la population défavorisée) ²

Ce modèle introduit un terme polynomial (% de la population défavorisée) ² pour capturer la non-linéarité de la relation entre le % de la population défavorisée et le prix médian des logements. La justification repose sur l'observation graphique de la relation non linéaire entre ces deux variables.

$$\text{Prix médian logements} = \beta_0 + \beta_1 \times \% \text{ de la population défavorisée} + \beta_2 \times (\% \text{ de la population défavorisée})^2 + \varepsilon$$

Après l'estimation des paramètres, on observe que si le pourcentage de la population défavorisée augmente de 1 %, alors le prix médian des maisons diminue de \$1 955. Cependant plus le % de la population défavorisée augmente, plus la baisse du prix ralentit. L'effet "négatif" s'atténue.

Ce modèle explique environ 66 % de la variance du prix médian des maisons.

3.3 Troisième modèle — modèle complet

3.3.1 Construction du modèle

Ce troisième modèle contient toutes les variables incluses dans le jeu de données. Après sa construction, il nous permettra de sélectionner les variables pertinentes grâce à l'aide des méthodes (Forward, Backward, Stepwise, Exhaustive) qui utilisent ce modèle de base pour ensuite fournir le meilleur selon le critère choisis.

Ce modèle s'écrit sous la forme :

$$\begin{aligned} \text{Prix médian logements} = & \beta_0 + \beta_1 \cdot \text{Taux de criminalité} + \beta_2 \cdot \\ & \% \text{ terrains résidentiels zonés} + \beta_3 \cdot \% \text{ acres commercial non résidentiel} + \beta_4 \cdot \\ & \text{Bordure rivière Charles} + \beta_5 \cdot \text{Concentration oxydes nitriques} + \beta_6 \cdot \\ & \text{nombre pièces logements} + \beta_7 \cdot \text{age} + \beta_8 \cdot \text{dis} + \beta_9 \cdot \text{rad} + \beta_{10} \cdot \text{Taux d'imposition} + \\ & \beta_{11} \cdot \text{ptratio} + \beta_{12} \cdot \text{lstat} + \beta_{13} \cdot \text{lstat}^2 + \varepsilon \end{aligned}$$

3.3.2 Vérification des hypothèses

3.3.2.1 Multicolinéarité

Vérification par le VIF (Variance Inflation Factor). Un VIF supérieur à 5 (ou 10 selon le seuil retenu) indique une multicolinéarité problématique. Nous avons calculé le VIF pour chaque variable du modèle complet. La règle généralement admise est qu'un VIF inférieur à 5 est acceptable, et qu'un VIF supérieur à 10 indique une multicolinéarité sévère nécessitant une action corrective (suppression de la variable ou regroupement).

Les variables d'indice d'accessibilité aux autoroutes et du taux d'imposition présentent des VIF élevés, confirmant la colinéarité identifiée dans la matrice GGpairs. Nous avons donc décidé de retirer la variable avec le VIF le plus élevé c'est à dire le taux d'imposition qui a un vif de 8,819 contre 7,327 pour l'indice d'accessibilité aux autoroutes. Nous conserverons donc 12 variables lors des méthodes pas à pas et exhaustives.

3.3.2.2 Linéarité et Homoscédasticité


Le graphique des résidus en fonction des valeurs ajustées (*Residuals vs Fitted*) permet de détecter deux types de violations : une relation non linéaire entre les prédicteurs et la variable cible (se manifestant par une forme en U dans les résidus), et une hétéroscédasticité (variance des résidus non constante, se manifestant par une forme en entonnoir).

On observe une légère courbure dans les résidus, cohérente avec la non-linéarité du % de la population défavorisée déjà identifiée lors de l'analyse bivariable. C'est précisément ce constat qui a motivé l'introduction du terme polynomial (% de population défavorisée)² dans nos modèles. Par ailleurs, une forme d'hétéroscédasticité modérée est visible, notamment pour les valeurs ajustées élevées.


3.3.2.3 Normalité des erreurs

Le QQ-plot des résidus montre des déviations aux extrémités de la distribution, en particulier dans la queue supérieure droite.

Le test de Shapiro-Wilk confirme formellement que les résidus ne suivent pas une loi normale ($p\text{-value} < 0,05$). Ce résultat est attendu compte tenu de la structure des données ; il ne remet pas en cause la pertinence de nos modèles dans un contexte prédictif car d'après le théorème central limite nos erreurs suivent asymptotiquement une loi normale. Ce qui confirme la validité de nos tests statistiques




3.3.2.4 Distribution des erreurs - Résidus studentisés



La visualisation des résidus studentisés permet de vérifier que les erreurs se distribuent de façon homogène autour de zéro, sans structure particulière. La majorité des résidus se situe dans l'intervalle $[-2 ; +2]$, ce qui est satisfaisant. On ne décèle pas de tendance systématique dans la distribution des résidus, ce qui ne contredit pas l'hypothèse d'indépendance des erreurs. Ce jeu de données ne constituant pas une série temporelle ordonnée.

3.3.2.5 Points influents et outliers



L'analyse des distances de Cook permet d'identifier les observations qui exercent une influence disproportionnée sur l'estimation des coefficients. Plusieurs observations dépassent le seuil classique de $4/n \approx 0,008$. Ces observations influentes seront prises en compte dans l'interprétation des résultats, mais ne seront pas supprimées, conformément à la décision prise en amont avec les professeurs.

IV. Sélection du Meilleur Modèle

Tous les modèles sont évalués par validation croisée. La validation croisée fournit une estimation robuste du RMSE.

Vue d'ensemble des modèles évalués :

Modèle	Variables
Modèle 1	Nombre moyen de pièces par logement
Modèle 2	% population à faible statut socio-éco + (% population à faible statut socio-éco) ²
Modèle 3	Toutes variables + % population à faible statut socio-éco ²
Forward	Sélection progressive
Backward	Élimination progressive
Stepwise	Ajout/retrait combiné
Exhaustive	Regsubsets

Chaque méthode de sélection cherche le sous-ensemble de variables qui minimise le RMSE, ni l'AIC, ni le BIC, ni le R^2 ne sont utilisés comme critères de décision. En revanche nous prendrons en compte l'effet de l'ajout de chaque variable sur la RMSE, nous préférons garder un bon modèle avec moins de variables qu'un modèle complexe légèrement meilleur.

Le choix du modèle final se reposera sur la recherche du point d'inflexion où l'erreur de prédiction se stabilise. Ici dans nos modèles notre erreur de prédiction se stabilise à partir de 7 variables dans le modèle. Nous garderons donc 7 variables.

Au-delà de ce nombre optimal de variables, le modèle est sous-ajusté (underfitting) et manque de pouvoir explicatif. À l'inverse, dépasser ce seuil reviendrait à capturer le bruit aléatoire des données plutôt que leur structure réelle, provoquant un surapprentissage (overfitting) préjudiciable à la capacité de généralisation du modèle sur de nouvelles observations.

4.1 Méthode Forward (sélection progressive)

La méthode Forward consiste à enrichir itérativement un modèle initialement vide en y injectant, à chaque étape, la variable minimisant l'erreur quadratique moyenne (RMSE).

La méthode Forward retient 10 variables avec un RMSE moyen de \$3627.

Nous garderons le modèle à 7 variables avec un RMSE moyen de \$3635 qui constitue un point d'inflexion où l'erreur de prédiction se stabilise.

4.2 Méthode Backward (élimination progressive)

On part du modèle complet (13 variables + (% de la population défavorisée)²) et on retire à chaque étape la variable dont la suppression réduit le plus le RMSE. On s'arrête à l'étape donnant le RMSE minimum.

Contrairement à la méthode Forward qui construit le modèle progressivement, Backward part de la complexité maximale et élimine les variables une par une afin de minimiser la RMSE.

La méthode Backward retient 9 variables avec un RMSE de \$3619.

Nous garderons le modèle à 7 variables avec un RMSE moyen de \$3643.

4.3 Méthode Stepwise

La méthode Stepwise est une combinaison des deux précédentes : à chaque étape, elle évalue simultanément l'ajout et le retrait d'une variable, et choisit l'action qui réduit le plus le RMSE. Cette flexibilité lui permet de corriger des erreurs commises aux étapes précédentes.

La méthode Stepwise retient 10 variables avec un RMSE de \$3642.

Nous garderons le modèle à 7 variables avec un RMSE moyen de \$3671.

4.4 Méthode Exhaustive

La méthode exhaustive teste tous les sous-ensembles possibles de variables pour chaque taille de modèle (de 1 à 12 variables), grâce à la fonction `regsubsets()`. Pour chaque taille, le meilleur sous-ensemble minimisant la RMSE est retenu. C'est la méthode la plus complète mais aussi la plus coûteuse en calcul. Contrairement aux méthodes Forward et Backward qui suivent un chemin unique, la méthode exhaustive garantit d'avoir testé toutes les combinaisons possibles pour chaque taille de modèle (nombre de variables).

La méthode Exhaustive retient 11 variables avec un RMSE de \$3626.

Nous garderons le modèle à 7 variables avec un RMSE moyen de \$3632

4.5 Comparaison finale

Une fois les quatre méthodes de sélection appliquées, on compare l'ensemble des 7 modèles (les 3 modèles candidats de départ + les 4 modèles sélectionnés) sur la base du RMSE. Le modèle avec le RMSE le plus faible relativement au nombre de variables est retenu comme modèle final.

Modèle / Méthode de sélection	Nombre de variables	RMSE moyen (K-fold)
Modèle 1 — Nb moyen de pièces	1	5.7114
Modèle 2 — % pop. défavorisée + carré	2	4.5847
Modèle 3 — complet (sans tax)	12	3.6151
Forward	7	3.6351
Backward	7	3.6426
Stepwise	7	3.6708
Exhaustive	7	3.6318

On observe que les 4 modèles obtenus avec les 4 méthodes différentes sont constitués avec les mêmes variables comme le montre le tableau suivant :

Méthode	Variables retenues
Forward	% pop. défavorisée, % pop. défavorisée ² , Nb moyen de pièces, Ratio élèves/enseignant, Taux de criminalité, Distance centres d'emploi, Pollution (NOx)
Backward	Taux de criminalité, Pollution (NOx), Nb moyen de pièces, Distance centres d'emploi, Ratio élèves/enseignant, % pop. défavorisée, % pop. défavorisée ²
Stepwise	% pop. défavorisée, Nb moyen de pièces, Ratio élèves/enseignant, % pop. défavorisée ² , Taux de criminalité, Distance centres d'emploi, Pollution (NOx)
Exhaustive	Taux de criminalité, Pollution (NOx), Nb moyen de pièces, Distance centres d'emploi, Ratio élèves/enseignant, % pop. défavorisée, % pop. défavorisée ²

V. Modèle Final

5.1 Présentation du modèle retenu

L'équation du modèle et l'ensemble des variables retenues sont donc présentés ci-dessous.

$$\text{Prix médian des maisons} = \beta_0 + \beta_1 \cdot \text{Taux de criminalité} + \beta_2 \cdot \text{Concentration oxydes nitriques} + \beta_3 \cdot \text{rm} + \beta_4 \cdot \text{dis} + \beta_5 \cdot \text{ptratio} + \beta_6 \cdot \text{lstat} + \beta_7 \cdot \text{lstat}^2 + \varepsilon$$

5.2 Etude des hypothèses du modèle

Avant d'interpréter les coefficients du modèle final, il est nécessaire de vérifier que les hypothèses classiques du modèle linéaire sont satisfaites. Cinq hypothèses ont été testées.

Linéarité des erreurs. Le graphique Residuals vs Fitted montre que les résidus sont répartis aléatoirement autour de zéro sans structure de courbure apparente. De plus, par construction des Moindres Carrés Ordinaires, les résidus sont toujours centrés en moyenne cette hypothèse est donc vérifiée par définition.

Homoscédasticité des erreurs. Le test de Breusch-Pagan rejette l'hypothèse d'homoscédasticité ($p < 0,05$). On observe sur le graphique Scale-Location une légère tendance croissante, indiquant que la variance des résidus augmente avec les valeurs ajustées. Cette hétéroscédasticité est fréquente sur des données immobilières où les prix élevés sont naturellement plus variables que les prix bas. Elle implique que les erreurs-standards des coefficients sont légèrement biaisées, mais l'impact sur les estimations ponctuelles reste limité.

Indépendance des erreurs. Le test de Durbin-Watson indique une légère autocorrélation des résidus ($p < 0,05$). Ce résultat s'explique par la structure spatiale du dataset : les observations voisines géographiquement partagent des caractéristiques communes non capturées par les variables du modèle. Dans un contexte de prédiction cette violation a un impact limité sur la qualité des prédictions.

Normalité des résidus. Les tests de Shapiro-Wilk et Anderson-Darling rejettent la normalité des résidus ($p < 0,05$). Le Q-Q plot révèle des écarts dans les queues de distribution, principalement sur les valeurs extrêmes. Cependant, avec 490 observations, le Théorème Central Limite garantit que les erreurs de notre modèle suivent asymptotiquement une loi normale. Les tests de significativité et les intervalles de confiance restent donc valides malgré cette violation.

Absence de multicolinéarité. Les VIF de toutes les variables du modèle final sont dans des plages acceptables, à l'exception du couple $\text{lstat} / \text{lstat}^2$ dont les VIF élevés sont normaux et attendus pour un terme polynomial — ils ne reflètent pas une vraie colinéarité problématique mais une dépendance mathématique structurelle entre une variable et son carré. Cette hypothèse est donc validée.

5.3 Etude des individus influents

L'étude des résidus du modèle final permet d'identifier trois catégories d'observations qui méritent une attention particulière.


Les observations influentes et atypiques cumulent deux problèmes simultanément : elles se situent dans une zone extrême de l'espace des prédicteurs et le modèle les prédit mal. Leur présence tire les coefficients dans une direction qui ne reflète pas la tendance générale. Dans notre cas, ces observations correspondent typiquement à des quartiers à très forte criminalité combinée à des caractéristiques socio-économiques extrêmes — des configurations rares que le modèle linéaire capture difficilement. Leur retrait modifierait sensiblement certains coefficients, notamment celui du taux de criminalité.

Les observations à fort levier ont des valeurs de prédicteurs très éloignées du centre du nuage mais sont correctement expliquées par le modèle. Elles ancrent la droite de régression sur ses extrémités sans la déformer. Dans notre espace à 7 dimensions, ce sont souvent des quartiers présentant une combinaison inhabituelle de caractéristiques — par exemple un ratio scolaire très bas combiné à un taux de population défavorisée élevé, ce qui est atypique dans notre jeu de données

Les observations atypiques ont un grand résidu mais un levier faible. Le modèle les prédit mal, mais leur position dans l'espace des prédicteurs est banale — elles n'influencent donc pas les coefficients. Elles correspondent souvent à des logements dont le prix s'écarte de la tendance pour des raisons non capturées par nos 7 variables : rénovation récente, vue exceptionnelle, vente en urgence, ou simplement la variabilité naturelle du marché immobilier.

La présence de ces observations non ordinaires est cohérente avec les violations d'hypothèses observées précédemment — hétéroscédasticité et non-normalité des queues de distribution. Elle n'invalide pas le modèle pour autant. Notre objectif étant la prédiction et notre critère de sélection étant le RMSE en validation croisée, ces observations étaient déjà présentes lors de l'évaluation. La performance prédictive annoncée reste donc valide sur l'ensemble de la distribution, y compris pour ces cas atypiques.

5.4 Etude de l'influence des variables



Variables à impact négatif sur les prix

- **Taux de criminalité : coeff. standardisé ≈ 0** : l'effet est statistiquement significatif ($p < 0.001$) mais le coefficient standardisé est le plus faible du modèle. Cela signifie qu'un écart-type de variation de la criminalité produit un impact marginal sur le prix médian une fois les autres facteurs contrôlés. La criminalité contribue au modèle, mais c'est un facteur secondaire.
- **Pollution atmosphérique : coeff. standardisé ≈ -4** : un écart-type de hausse de la concentration en oxydes nitriques entraîne une baisse d'environ 4 k\$ du prix médian. C'est un effet important sur le modèle.
- **Distance aux centres d'emploi : coeff. standardisé ≈ -2** : s'éloigner d'un écart-type des pôles d'emploi réduit le prix médian d'environ 2 k\$. L'accessibilité au travail est un critère déterminant dans les choix résidentiels — les quartiers périphériques sont pénalisés par le marché.
- **Ratio élèves/enseignants : coeff. standardisé ≈ -3** : un écart-type de hausse du ratio scolaire (classes plus surchargées) réduit le prix médian d'environ 3 k\$. La qualité perçue des écoles est un signal fort pour les acheteurs avec enfants — son effet est le troisième plus fort parmi les variables négatives.
- **Statut socio-économique : coeff. standardisé ≈ -9** c'est de loin l'effet dominant du modèle. Un écart-type de hausse du taux de population défavorisée entraîne une chute de ~ 9 k\$ du prix médian. La relation est cependant **non linéaire** : le coefficient positif de (% de population défavorisée)² indique que cet effet négatif s'atténue progressivement. Concrètement, passer de 2% à 10% de population défavorisée pèse beaucoup plus sur les prix que passer de 25% à 33% — dans les quartiers déjà très défavorisés, le marché a atteint un plancher et la dégradation supplémentaire du statut socio-économique a un impact moindre.

Variables à impact positif sur les prix

- **Nombre de pièces coeff. Standardisé ≈ 5** : c'est la seule variable à effet positif dominant. Un écart-type supplémentaire du nombre moyen de pièces augmente le prix médian d'environ 5 k\$. C'est le deuxième effet le plus fort du modèle en valeur absolue, juste après le % de population défavorisée.


5.3 Diagnostics du modèle final

Si les tests d'hypothèses classiques (Shapiro, Breusch-Pagan) pointent des limites théoriques (hétéroscédasticité, non normalité des résidus) le modèle reste valide pour un usage opérationnel. Le volume de données ($n=490$) assure la validité des tests via le TCL, tandis que les graphiques de diagnostic confirment l'absence de biais structurel dans les résidus. La performance étant ici mesurée par le RMSE moyen en validation croisée, la stabilité observée sur les différents folds prouve la capacité du modèle à généraliser ses prédictions. En privilégiant la robustesse prédictive à la perfection théorique, nous retenons ce modèle comme une base fiable pour l'estimation immobilière.

VI. Prédictions Concrètes à Boston

6.1 Application du modèle

Le modèle final est appliqué à des profils de logements types à Boston, afin de produire des prédictions concrètes du prix médian accompagnées de leurs intervalles de confiance à 95%. Les prédictions sont exprimées en milliers de dollars (k\$). Les intervalles de confiance reflètent les estimations du prix médian des maisons dans les quartiers à logement équivalent. Là où les intervalles de prédiction permettent d'estimer le prix médian d'un logement dans l'un de ces quartiers.



Le graphique illustre concrètement l'amplitude des inégalités immobilières captées par le modèle. Un logement en quartier aisé est prédit autour de 33,3 k\$, avec un intervalle de prévision à 95% de [26,1 ; 40,5]

Un logement en quartier moyen est estimé aux alentours de 22,5 k\$ [15,3 ; 29,6]. Enfin, un logement en quartier défavorisé est prédit à environ 14,3 k\$, avec un intervalle [7 ; 21,4].

L'écart entre le quartier aisé et le quartier défavorisé atteint ainsi ~25 k\$, soit près du triple du prix prédit pour le profil le moins favorable. Cet écart est entièrement expliqué par les variables structurelles et socio-économiques du modèle, ce qui souligne le rôle central du contexte de vie — qualité scolaire, niveau socio-économique du voisinage, pollution — dans la formation des prix immobiliers.

Ces intervalles de prévision larges (~±14 k\$) rappellent néanmoins la limite principale du modèle : une part significative de la variabilité du prix reste inexpliquée, probablement en raison des variables manquantes et de la censure à 50 000 \$ évoquées précédemment. Ces résultats, cohérents avec le contexte des années 1970, constituent une base solide qui pourrait être affinée par des approches plus complexes telles que le Random Forest ou XGBoost.

VII. Conclusion

7.1 Modèle final

Les modèles simples M1 (Nombres moyen de pièces seul, RMSE = 6,635 k\$) et M2 (% de population défavorisée + (% de population défavorisée)², RMSE=5,518k\$) confirment qu'une seule variable ou deux, aussi corrélées soient-elles avec medv, restent insuffisantes pour capturer toute la complexité du marché immobilier bostonien. L'ajout progressif des variables socio-économiques, environnementales et structurelles réduit l'erreur de prédiction de près de 2 k\$ par rapport au meilleur modèle simple.

7.2 Interprétation des résultats

Les résultats confirment que le prix médian des logements à Boston est principalement déterminé par trois grandes familles de facteurs.

Le cadre de vie immédiat : le nombre de pièces est la variable à effet positif le plus fort — chaque pièce supplémentaire est associée à une hausse significative du prix. À l'inverse, la concentration en oxydes nitriques (Concentration oxydes nitriques) agit négativement : un environnement pollué déprécie fortement les biens immobiliers.

Le profil socio-économique du quartier : le pourcentage de population défavorisée est le prédicteur négatif le plus puissant, avec une relation non linéaire (capturée par (% de la population défavorisée)²) : la dépréciation des prix est plus forte dans les quartiers modestement défavorisés que dans les quartiers très défavorisés, où elle ralentit.

La qualité des services publics : le ratio élèves/enseignant reflète indirectement la qualité du système scolaire local. Plus ce ratio est élevé (classes surchargées), plus le prix médian tend à baisser.

Le graphique en forêt résume visuellement l'impact de chaque variable : les barres à droite de zéro indiquent un effet positif sur le prix, celles à gauche un effet négatif. Les variables dont l'intervalle de confiance ne croise pas zéro sont statistiquement significatives au seuil de 5%

7.3 Limites et perspectives

- Variables manquantes : des facteurs potentiellement explicatifs sont absents du jeu de données, notamment la surface habitable en m², la proximité aux écoles, aux transports en commun ou aux commerces, et la qualité intrinsèque de la construction.
- Données datant de 1970 : le marché immobilier bostonien a profondément évolué depuis la collecte de ces données. Les coefficients estimés ne sont pas directement transposables au marché actuel.
- Pistes d'amélioration : des méthodes non paramétriques comme les forêts aléatoires (*Random Forest*) ou le gradient boosting (*XGBoost*) pourraient capturer des non-linéarités plus complexes et améliorer le RMSE. Une régression sur le prix médian

des maisons tronquée (modèle tobit) permettrait également de mieux traiter le problème de censure.